Phân tích cảm xúc và trích xuất vấn đề từ đánh giá thương mại điện tử bằng NLP cổ điển và mở rộng Transformer

Báo cáo học thuật theo form paper, đồng bộ code hiện trạng

Đội: Team SkyDom+

Thành viên nhóm:

Nguyen Nhu Tien Tuan	22BA13314
Tran Hien Chuong	22BA13056
Do Gia Bao	22BA13042
Bui The Anh	22BA13007
Le Duc An	22BA13002
Pham Quang Tung	22BA13320
Khuong Bao Duc	22BA13077

Ngày cập nhật: 12/03/2026

Abstract

Báo cáo này viết lại theo đúng cấu trúc paper và đồng bộ tuyệt đối với trạng thái repository hiện tại (commit `d9c7e6f`). Hệ thống gồm ba nhiệm vụ: phân loại cảm xúc nhị phân có cơ chế bất định, trích xuất issue đa nhãn, và mở rộng bằng transformer. Dữ liệu nguồn gồm 152.410 review; bộ dữ liệu issue đã gán nhãn gồm 19.000 dòng. Với sentiment cổ điển, biến thể V6 (word 1–2 + char 3–5 + negation, class weight w10) đạt test `precision_0=0.677`, `recall_0=0.932`, `F2_0=0.867`, coverage 0.885 ở dải ngưỡng 0.40/0.60. Mô hình transformer sentiment đạt `accuracy=0.966`, `precision_0=0.799`, `recall_0=0.853`, `F2_0=0.842`, coverage 0.910. Với issue extraction trên tập test 3.800 mẫu, OVR Logistic đạt `micro-F1=0.780`, `macro-F1=0.387`; OVR LinearSVM đạt `micro-F1=0.771`, `macro-F1=0.405`; trong khi dummy baseline có micro-F1 cao (`0.809`) nhưng macro-F1 rất thấp (`0.101`) do lệch nhãn `other`. Gói nâng cấp không thêm dữ liệu mở rộng thêm benchmark giáo trình, n-gram LM, bootstrap/significance, và thử nghiệm transformer issue + hybrid routing. Toàn bộ số liệu trong báo cáo lấy trực tiếp từ artifact trong thư mục `results/`.

Contents

1 Giới thiệu **1**

2 Định nghĩa bài toán NLP **1**
2.1 Task A: Hiểu cảm xúc 1
2.2 Task B: Trích xuất issue 1
2.3 Task C: Mở rộng ngữ cảnh sâu 1

3 Dữ liệu và đặc trưng ngôn ngữ **1**
3.1 Nguồn dữ liệu và quy mô 1
3.2 Nhiễu ngôn ngữ quan sát được 2
3.3 Dữ liệu gán nhãn issue 2

4 Thiết kế xử lý văn bản **3**
4.1 Chuẩn hóa 3
4.2 Xử lý phủ định 3
4.3 Xử lý tương phản 3
4.4 Mô hình hóa mức ký tự 3

5 Thiết kế đặc trưng **3**
5.1 Biểu diễn sparse cổ điển 3
5.2 Khối đặc trưng lexicon 3

6 Hướng mô hình hóa **4**
6.1 Bộ phân loại sentiment 4
6.2 Mô hình issue extraction 4
6.3 Mở rộng Transformer 4

7 Thiết lập thực nghiệm **4**
7.1 Chia tập và giao thức 4
7.2 Chỉ số chính 4
7.3 Quy tắc bất định 4

8 Gói nâng cấp không thêm dữ liệu **5**

9 Kết quả cho sentiment NLP cổ điển **5**
9.1 Chọn baseline theo K 5
9.2 So sánh biến thể 5
9.3 Hành vi theo ngưỡng và bất định 6

10 Kết quả cho mở rộng Transformer NLP **6**
10.1 Chỉ số Transformer 6
10.2 Quét ngưỡng Transformer 7
10.3 So sánh hard-case 7

11 Kết quả cho NLP Issue Extraction **7**
11.1 Kết quả tổng thể đa nhãn 7
11.2 Chênh lệch theo từng nhãn 7
11.3 Chiến lược ngưỡng trong bối cảnh đa nhãn 8

12 Kết quả cho gói nâng cấp giáo trình **9**
12.1 Baseline cổ điển cho các thuật toán cốt lõi 9
12.2 Hành vi selective của các baseline bổ sung 9
12.3 Kết quả N-Gram Language Model 9
12.4 Ma trận bao phủ học phần cập nhật 10

13 Thảo luận Classic so với Transformer **10**

14 Phân tích lỗi và failure modes **10**

15 Giá trị thực tiễn cho học phần NLP **11**

16 Hạn chế và hướng phát triển **11**

17 Kết luận **11**

Tài liệu tham khảo **12**

Phụ lục A: Hình sentiment **13**

Phụ lục B: Hình issue extraction **18**

Phụ lục C: Hình gói nâng cấp giáo trình **20**

1 Giới thiệu

Ngôn ngữ trong review ngắn, nhiễu và thường trộn nhiều sắc thái trong cùng một câu. Vì vậy bài toán được triển khai như một pipeline NLP hoàn chỉnh thay vì chỉ so sánh một mô hình phân loại đơn lẻ [1, 2].

Bản báo cáo này giữ đúng form paper tham chiếu, đồng thời cập nhật toàn bộ kết quả theo code hiện tại. Phạm vi nâng cấp bám nguyên tắc không thêm dữ liệu mới: chỉ cải tiến xử lý, mô hình hóa, hiệu chỉnh và đánh giá.

2 Định nghĩa bài toán NLP

2.1 Task A: Hiểu cảm xúc

Task A là phân loại cảm xúc nhị phân từ văn bản review. Rating 1–2 ánh xạ về lớp 0 (negative), rating 4–5 ánh xạ về lớp 1 (positive), rating 3 dành cho phân tích bất định. Do dữ liệu mất cân bằng mạnh (xấp xỉ 9,5:1), tiêu chí chọn mô hình theo thứ tự ưu tiên: `recall_0` rồi `F2_0` rồi `precision_0`.

2.2 Task B: Trích xuất issue

Task B là gán đa nhãn issue với 9 nhãn (delivery, redemption, product quality, customer service, refund, usability, value/price, fraud/scam, other). Đây là ánh xạ từ văn bản không cấu trúc sang tín hiệu vận hành có cấu trúc [4, 5].

2.3 Task C: Mở rộng ngữ cảnh sâu

Task C dùng transformer fine-tuning để kiểm tra năng lực mô hình hóa ngữ cảnh sâu, xử lý case khó và so sánh trực tiếp với hướng sparse cổ điển [6, 7].

3 Dữ liệu và đặc trưng ngôn ngữ

3.1 Nguồn dữ liệu và quy mô

Tập nguồn có 152.410 review. Phân bố rating được trình bày ở Bảng 1.

Table 1: Phân bố rating trong dữ liệu nguồn

Rating	Số lượng
1	12.326
2	1.873
3	3.271
4	6.692
5	128.248

Phần strong-label sentiment (rating 1,2,4,5) có 149.139 dòng, gồm 14.199 negative và 134.940 positive.

3.2 Nhiễu ngôn ngữ quan sát được

Dữ liệu có nhiều dạng nhiễu: viết tắt (*gr8*, *thx*, *idk*), câu rất ngắn, lỗi chính tả, và câu trộn polarity như *good but late delivery*. Các hiện tượng negation và contrast xuất hiện thường xuyên.

3.3 Dữ liệu gán nhãn issue

Bộ issue hợp nhất có 19.000 dòng. Tần suất nhãn được trình bày ở Bảng 2.

Table 2: Tần suất nhãn issue trong bộ gán nhãn

Nhãn	Số lượng	Tỷ lệ
delivery_shipping	972	0,0512
redemption_activation	284	0,0149
product_quality	1.251	0,0658
customer_service	182	0,0096
refund_return	93	0,0049
usability	873	0,0459
value_price	558	0,0294
fraud_scam	144	0,0076
other	15.960	0,8400

4 Thiết kế xử lý văn bản

4.1 Chuẩn hóa

Pipeline chuẩn hóa gồm chuyển chữ thường, loại URL, chuẩn hóa dấu câu và khoảng trắng. Mục tiêu là giảm sparsity nhưng vẫn giữ tín hiệu cảm xúc.

4.2 Xử lý phủ định

Pipeline sentiment và issue hỗ trợ truyền dấu phủ định theo cửa sổ cục bộ (cấu hình issue hiện tại: cửa sổ 3 token). Đây là thành phần quan trọng để xử lý lật polarity.

4.3 Xử lý tương phản

Các tín hiệu tương phản như *but*, *however* được hấp thụ thông qua n-gram biểu diễn cụm từ, giúp mô hình học chuyển pha sắc thái trong câu.

4.4 Mô hình hóa mức ký tự

Character n-gram (3–5) được kết hợp với word n-gram để tăng độ bền trước lỗi chính tả, viết tắt và biến thể bề mặt.

5 Thiết kế đặc trưng

5.1 Biểu diễn sparse cổ điển

Biểu diễn chính cho sentiment là TF-IDF word n-gram (1–2) + char n-gram (3–5), sau đó chọn đặc trưng bằng Chi-square. Biến thể tốt nhất V6 dùng `k=10000`.

Với issue extraction, pipeline dùng TF-IDF, hỗ trợ char n-gram tùy chọn, và Chi-square với `k=2000` trước tầng OVR.

5.2 Khối đặc trưng lexicon

Trong trạng thái hiện tại, mô hình tốt nhất là sparse data-driven. Các thành phần nghiêng về lexicon được giữ như khối phân tích bổ trợ trong gói mở rộng, không phải đường triển khai chính.

6 Hướng mô hình hóa

6.1 Bộ phân loại sentiment

Backbone sentiment cổ điển là Logistic Regression. Class-weight được dò trên `none`, `balanced`, `w2`, `w5`, `w10`. Các biến thể V0–V7 phản ánh bật/tắt xử lý và đặc trưng.

6.2 Mô hình issue extraction

Issue extraction dùng OVR Logistic Regression có hiệu chỉnh xác suất (sigmoid) và tuning ngưỡng theo từng nhãn. OVR LinearSVM và mô hình blend xác suất LR+SVM (`ovr_blend_lr_svm`) là nhóm so sánh mạnh, đồng thời có thêm hai dummy baseline (`dummy_labelset_majority`, `dummy_label_prior`) để kiểm tra sanity.

6.3 Mở rộng Transformer

Khối transformer dùng HuggingFace fine-tuning (họ DistilBERT theo script hiện tại) và đánh giá cùng chính sách ngưỡng bất định để so sánh trực tiếp với mô hình cổ điển.

7 Thiết lập thực nghiệm

7.1 Chia tập và giao thức

Sentiment huấn luyện trên tập strong-label (rating 1,2,4,5), giữ validation và test độc lập; rating 3 chỉ dùng cho phân tích bất định. Issue extraction chia cố định 13.300/1.900/3.800 (train/val/test). Khối issue-transformer báo cáo trên 3.000/1.000/2.000.

7.2 Chỉ số chính

Sentiment dùng các chỉ số `accuracy`, `F1`, `precision_0`, `recall_0`, `F1_0`, `F2_0`. Issue extraction dùng micro-F1, macro-F1, subset accuracy, hamming loss và F1 theo từng nhãn.

7.3 Quy tắc bất định

Selective classification dùng dải ngưỡng $[t_{low}, t_{high}]$. Mẫu nằm trong dải được gắn uncertain; ngoài dải là covered decisions. Báo cáo gồm coverage, selective precision_0, selective recall_0, selective F2_0 và tỷ lệ FN trên phần covered [9].

8 Gói nâng cấp không thêm dữ liệu

Các thành phần nâng cấp chính theo code hiện tại:

1. Level-3 issue: dò class-weight theo từng nhãn, calibration, và kiểm tra độ ổn định theo nhiễu ngưỡng.
2. Level-4 issue transformer và hybrid routing có giới hạn tỷ lệ route.
3. Bộ benchmark giáo trình: Naive Bayes, Perceptron, LinearSVM, SGD log-loss, SVD semantic baseline, FFNN MLP.
4. Module n-gram language model với add-k smoothing và perplexity.
5. Gói đánh giá nghiêm ngặt: bootstrap CI, kiểm định cặp mô hình, taxonomy lỗi.
6. Ma trận bao phủ học phần sinh trực tiếp từ artifact hiện có.

9 Kết quả cho sentiment NLP cổ điển

9.1 Chọn baseline theo K

Bảng 3 cho thấy cấu hình tốt nhất theo từng mức Chi-square K dưới tiêu chí negative-first.

Table 3: Baseline sentiment tốt nhất theo Chi-square K (validation)

K	Class weight	Precision_0	Recall_0	F2_0	Accuracy
1.000	w10	0,555	0,910	0,806	0,922
2.000	w10	0,584	0,920	0,825	0,930
5.000	balanced	0,606	0,935	0,843	0,936
10.000	balanced	0,621	0,936	0,850	0,940

9.2 So sánh biến thể

Bảng 4 báo cáo kết quả test các biến thể V0–V7; V6 là mô hình chính hiện tại.

Table 4: So sánh biến thể sentiment cổ điển trên test

Biến thể	K	Class weight	Precision_0	Recall_0	F2_0
V0	10.000	balanced	0,638	0,937	0,856
V1	10.000	balanced	0,643	0,932	0,855
V2	5.000	w10	0,647	0,926	0,852
V3	10.000	balanced	0,626	0,923	0,843
V4	10.000	balanced	0,635	0,921	0,845
V5	10.000	balanced	0,653	0,933	0,859
V6	10.000	w10	0,677	0,932	0,867
V7	5.000	w10	0,657	0,927	0,857

9.3 Hành vi theo ngưỡng và bất định

Với V6, dải ngưỡng khuyến nghị là 0,40/0,60. Bảng 5 thể hiện trade-off theo dịch chuyển ngưỡng.

Table 5: Quét ngưỡng của sentiment cổ điển trên test

Ngưỡng	Coverage	Sel. precision_0	Sel. recall_0	Sel. F2_0
0,40 / 0,60	0,885	0,730	0,956	0,900
0,45 / 0,60	0,891	0,708	0,956	0,894
0,50 / 0,65	0,886	0,681	0,963	0,889
0,55 / 0,70	0,881	0,646	0,970	0,882

10 Kết quả cho mở rộng Transformer NLP

10.1 Chỉ số Transformer

Bảng 6 tóm tắt kết quả sentiment transformer.

Table 6: Hiệu năng sentiment transformer

Tập	Accuracy	F1	Precision_0	Recall_0	F2_0	Coverage
Validation	0,966	0,981	0,793	0,870	0,854	0,906
Test	0,966	0,981	0,799	0,853	0,842	0,910

10.2 Quét ngưỡng Transformer

Table 7: Quét ngưỡng transformer trên test

Ngưỡng	Coverage	Sel. precision_0	Sel. recall_0	Sel. F2_0
0,40 / 0,60	0,910	0,831	0,846	0,843
0,45 / 0,60	0,911	0,827	0,847	0,843
0,50 / 0,65	0,912	0,821	0,850	0,844
0,55 / 0,70	0,911	0,818	0,855	0,847

10.3 So sánh hard-case

Kết quả hard-case cho thấy tính bổ sung giữa hai hướng. Với *not bad* và *good but late delivery*, mô hình cổ điển dự đoán negative còn transformer dự đoán positive. Với chuỗi rất ngắn (*gr8*, *thx*, *idk*), cả hai đều đẩy vào uncertain theo chính sách short-text.

11 Kết quả cho NLP Issue Extraction

11.1 Kết quả tổng thể đa nhãn

Bảng 8 trình bày kết quả pipeline issue chính hiện tại (test 3.800 mẫu).

Table 8: Chỉ số tổng thể issue extraction

Mô hình	Micro-F1	Macro-F1	Subset accuracy	Hamming loss
OVR Logistic (test)	0,780	0,387	0,634	0,0585
OVR LinearSVM (test)	0,771	0,405	0,617	0,0623
OVR Blend LR+SVM (test)	0,768	0,391	0,626	0,0620
Dummy labelset majority (test)	0,809	0,101	0,811	0,0438
Dummy label prior (test)	0,809	0,101	0,811	0,0438

Dummy baseline có thể cao ở micro-F1 và subset accuracy vì gần như luôn dự đoán nhãn `other`; macro-F1 cho thấy chúng không xử lý tốt các nhãn thiểu số.

11.2 Chênh lệch theo từng nhãn

Bảng 9 so sánh F1 từng nhãn giữa SVM và Logistic trên test.

Table 9: Chênh lệch F1 theo nhãn (SVM trừ Logistic)

Nhãn	Logistic F1	SVM F1	Δ
delivery_shipping	0,442	0,446	+0,004
redemption_activation	0,298	0,287	-0,010
product_quality	0,307	0,282	-0,025
customer_service	0,225	0,168	-0,057
refund_return	0,435	0,387	-0,048
usability	0,459	0,462	+0,003
value_price	0,258	0,313	+0,056
fraud_scam	0,150	0,391	+0,241
other	0,911	0,911	+0,001

11.3 Chiến lược ngưỡng trong bối cảnh đa nhãn

Ngưỡng theo từng nhãn của pipeline chính `ovr_logreg` được trình bày trong Bảng 10. Các nhãn hiếm được đặt ngưỡng thấp hơn để tăng recall; `fraud_scam` và `other` được giữ ngưỡng thận trọng hơn.

Table 10: Ngưỡng cuối cùng theo từng nhãn của pipeline issue

Nhãn	Ngưỡng
delivery_shipping	0,25
redemption_activation	0,10
product_quality	0,10
customer_service	0,10
refund_return	0,15
usability	0,10
value_price	0,15
fraud_scam	0,50
other	0,30

12 Kết quả cho gói nâng cấp giáo trình

12.1 Baseline cổ điển cho các thuật toán cốt lõi

Bảng 11 tổng hợp các baseline sentiment trong gói không thêm dữ liệu.

Table 11: Baseline benchmark giáo trình trên test

Mô hình	Recall_0	Precision_0	F2_0
logreg_l2	0,913	0,703	0,862
multinomial_nb	0,913	0,633	0,839
complement_nb	0,952	0,510	0,811
perceptron	0,828	0,684	0,795
linear_svm	0,847	0,789	0,835
sgd_log_loss	0,921	0,616	0,838
svd_semantic_logreg	0,920	0,501	0,788
ffnn_mlp_svd	0,730	0,799	0,742

12.2 Hành vi selective của các baseline bổ sung

Table 12: Chỉ số selective cho các baseline xác suất (test)

Mô hình	Coverage	Sel. precision_0	Sel. recall_0	Sel. F2_0
logreg_l2_selective	0,887	0,763	0,946	0,903
multinomial_nb_selective	0,903	0,654	0,928	0,857
complement_nb_selective	0,900	0,545	0,963	0,835
sgd_log_loss_selective	0,863	0,696	0,959	0,892

12.3 Kết quả N-Gram Language Model

Table 13: Perplexity của n-gram LM (add-k smoothing)

Mô hình	Perplexity validation	Perplexity test
Unigram add-k	376,51	378,02
Bigram add-k	358,59	363,08

12.4 Ma trận bao phủ học phần cập nhật

Bảng 14 thể hiện mức bao phủ chủ đề học phần theo artifact hiện có. Điểm trung bình đạt **94,3%**.

Table 14: Ma trận mức độ bao phủ học phần từ artifact hiện trạng

Chủ đề	Bao phủ (%)
Probability	100
Regular Expressions	50
Evaluation Measures	100
N-Gram Language Models	100
Naive Bayes	100
Perceptron	100
Logistic Regression	100
Feed-forward Neural Networks	100
Pytorch Basic	100
Vector Semantics and Embeddings	80
Recurrent Neural Networks	100
Transformers and LLMs	100
Masked Language Models	100
Applications of LLMs	90

13 Thảo luận Classic so với Transformer

Ở bài toán sentiment, transformer vượt trội về accuracy tổng thể và precision_0 (0,799 so với 0,677), trong khi classic V6 tốt hơn về recall_0 (0,932 so với 0,853) và F2_0 (0,867 so với 0,842). Khi dùng cùng dải ngưỡng 0,40/0,60, transformer có selective precision cao hơn nhưng selective recall thấp hơn classic.

Với issue extraction, mô hình classic đa nhãn hiện vẫn mạnh hơn transformer issue trong trạng thái code hiện tại (micro-F1 0,792 so với 0,646 theo file so sánh hybrid). Hybrid route cải thiện so với transformer thuần nhưng vẫn chưa vượt classic.

14 Phân tích lỗi và failure modes

Gói đánh giá nghiêm ngặt ghi nhận 1.454 mẫu sentiment dự đoán sai (194 false negative lớp 0 và 1.260 false positive lớp 0). Với false positive, nhóm lỗi lớn nhất là negation

pattern (49,8%), tiếp theo là ngữ cảnh khác (32,4%) và contrast pattern (10,4%). Với false negative, nhóm lớn nhất là ngữ cảnh khác (52,1%), short text (23,2%) và negation pattern (14,4%).

Kiểm định cặp mô hình cho thấy V6 có chênh lệch dương so với một số baseline (ví dụ recall_0 +0,063 so với multinomial NB, +0,085 so với LinearSVM), nhưng p-value vẫn lớn hơn 0,05 ở lần chạy này; do đó xem như xu hướng tích cực, chưa kết luận ý nghĩa thống kê mạnh.

15 Giá trị thực tiễn cho học phần NLP

Dự án hiện có chuỗi artifact tái lập đầy đủ: dữ liệu đã xử lý, script theo bước, model lưu, phân tích ngưỡng, chính sách uncertain, extension transformer, và gói đánh giá nghiêm ngặt. Điều này đáp ứng tốt cả mục tiêu triển khai kỹ thuật lẫn yêu cầu bảo vệ học thuật.

Gói nâng cấp giáo trình cải thiện rõ mức bao phủ chủ đề mà không cần mở rộng dữ liệu, phù hợp với hướng đánh giá trọng tâm phương pháp.

16 Hạn chế và hướng phát triển

Các hạn chế chính gồm mất cân bằng lớp mạnh, nhãn `other` chiếm ưu thế trong issue, và hiệu năng transformer đa nhãn còn thấp với cấu hình fine-tune hiện tại trên tập nhỏ. Taxonomy lỗi cũng cho thấy hệ thống vẫn nhạy với negation và câu tương phản phức hợp.

Hướng tiếp theo nên tập trung vào ensemble có calibration, tăng cường ngữ cảnh không thêm nhãn mới, và các mô hình chuỗi gọn nhẹ cho issue extraction nhưng vẫn giữ khả năng diễn giải.

17 Kết luận

Bản report mới đã đồng bộ hoàn toàn cấu trúc và số liệu với code hiện tại. Mô hình production chính cho sentiment vẫn là classic V6 vì đáp ứng tiêu chí recall/F2 cho lớp negative theo mục tiêu dự án. Transformer sentiment có lợi thế rõ ở precision và accuracy tổng thể, phù hợp vai trò bổ trợ. Với issue extraction, OVR classic có calibration vẫn là lựa chọn mạnh nhất trong trạng thái repository hiện nay. Gói nâng cấp không thêm dữ liệu đã nâng đáng kể tính học thuật, tính tái lập và độ phủ chủ đề của dự án.

Tài liệu tham khảo

References

[1] Dan Jurafsky and James H. Martin. *Speech and Language Processing* (3rd ed. draft). 2026.
https://web.stanford.edu/ jurafsky/slp3/

[2] Peter D. Turney. Thumbs Up or Thumbs Down? Semantic Orientation Applied to Unsupervised Classification of Reviews. In *Proceedings of ACL*, 2002.
https://aclanthology.org/P02-1053/

[3] Sida Wang and Christopher D. Manning. Baselines and Bigrams: Simple, Good Sentiment and Topic Classification. In *Proceedings of ACL*, 2012.
https://aclanthology.org/P12-2018/

[4] Grigorios Tsoumakas, Ioannis Katakis, and Ioannis Vlahavas. Random k-Labelsets for multilabel classification. *IEEE Transactions on Knowledge and Data Engineering*, 23(7):1079–1089, 2011.
https://doi.org/10.1109/TKDE.2010.164

[5] Min-Ling Zhang and Zhi-Hua Zhou. A review on multi-label learning algorithms. *IEEE Transactions on Knowledge and Data Engineering*, 26(8):1819–1837, 2014.
https://doi.org/10.1109/TKDE.2013.39

[6] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention Is All You Need. In *Advances in Neural Information Processing Systems 30*, 2017.
https://arxiv.org/abs/1706.03762

[7] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In *Proceedings of NAACL-HLT*, 2019.
https://aclanthology.org/N19-1423/

[8] Takaya Saito and Marc Rehmsmeier. The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, 10(3):e0118432, 2015.
https://doi.org/10.1371/journal.pone.0118432

[9] Yonatan Geifman and Ran El-Yaniv. Selective Classification for Deep Neural Networks. *arXiv preprint arXiv:1705.08500*, 2017.
https://arxiv.org/abs/1705.08500

Phụ lục A: Hình sentiment

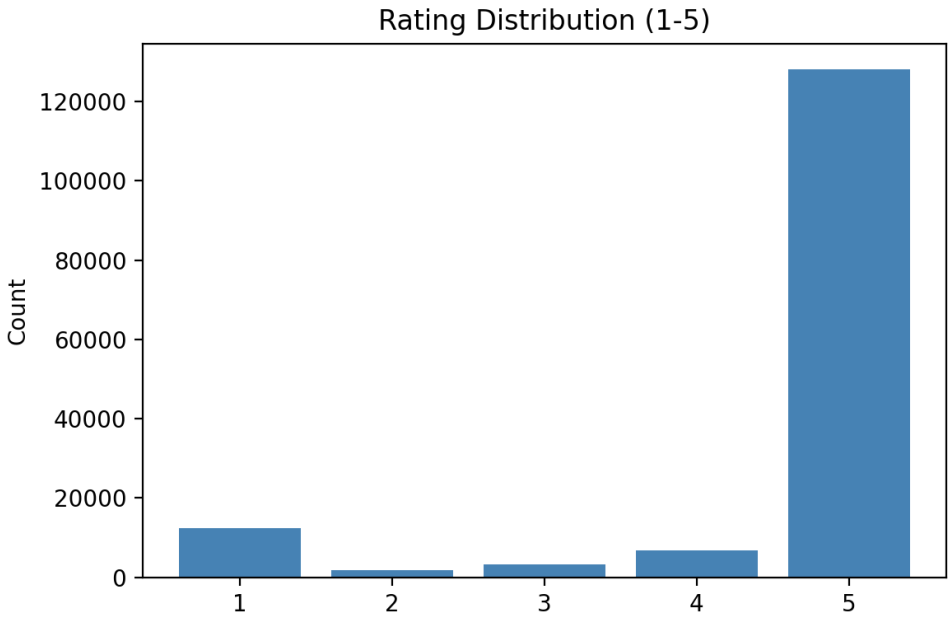

Figure 1: Phân bố rating dữ liệu nguồn

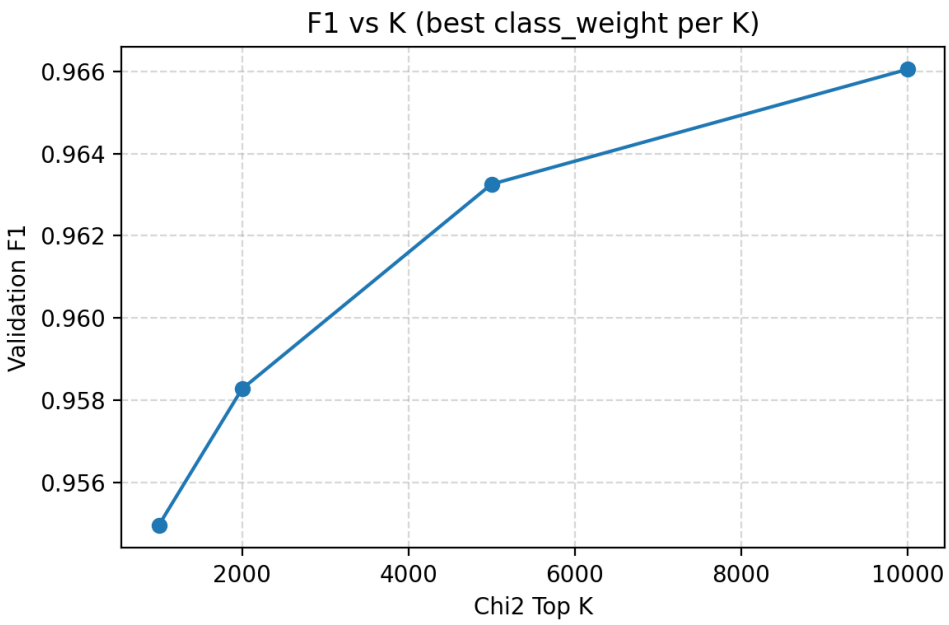

Figure 2: F1 validation theo Chi-square top K

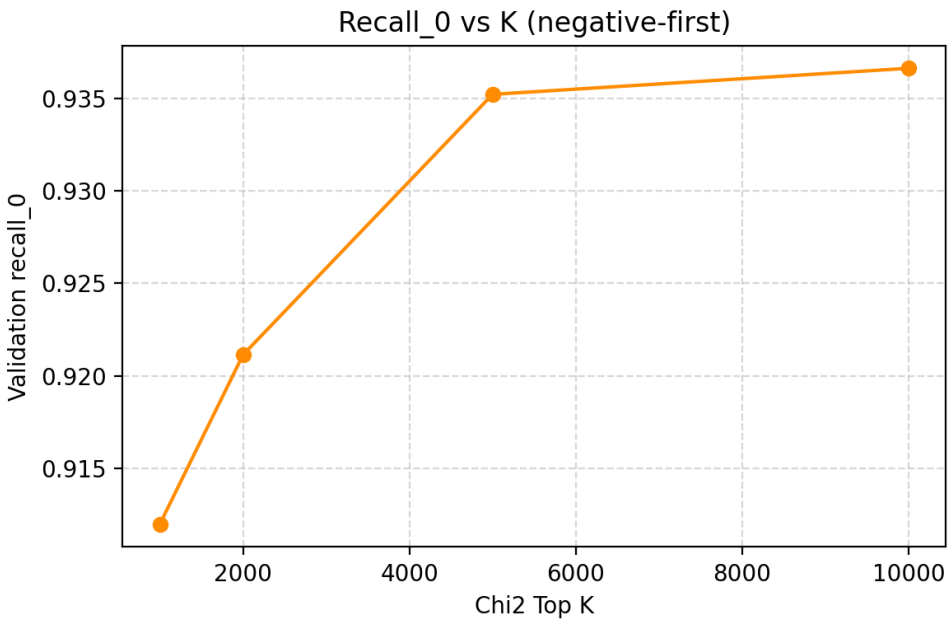

Figure 3: Recall lớp negative theo top K

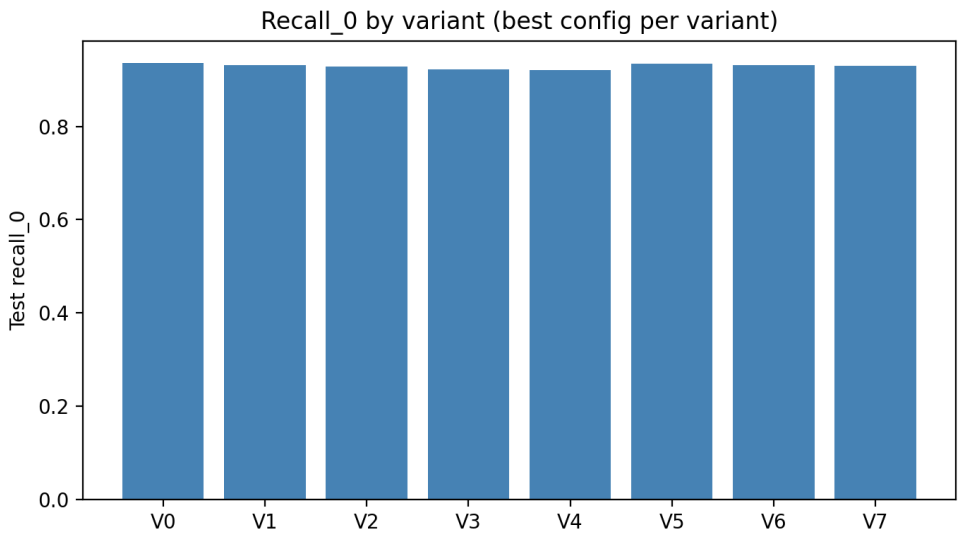

Figure 4: Recall lớp negative theo biến thể cổ điển

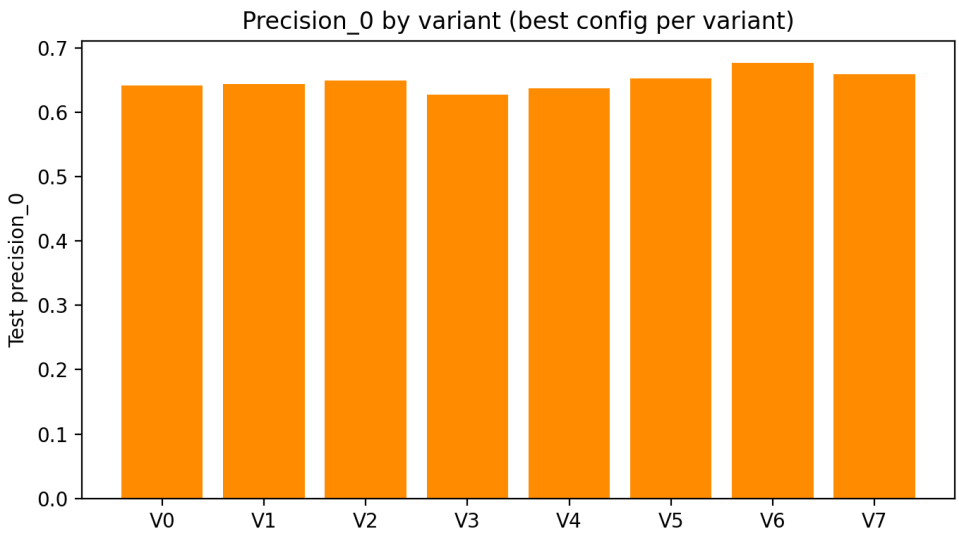

Figure 5: Precision lớp negative theo biến thể cổ điển

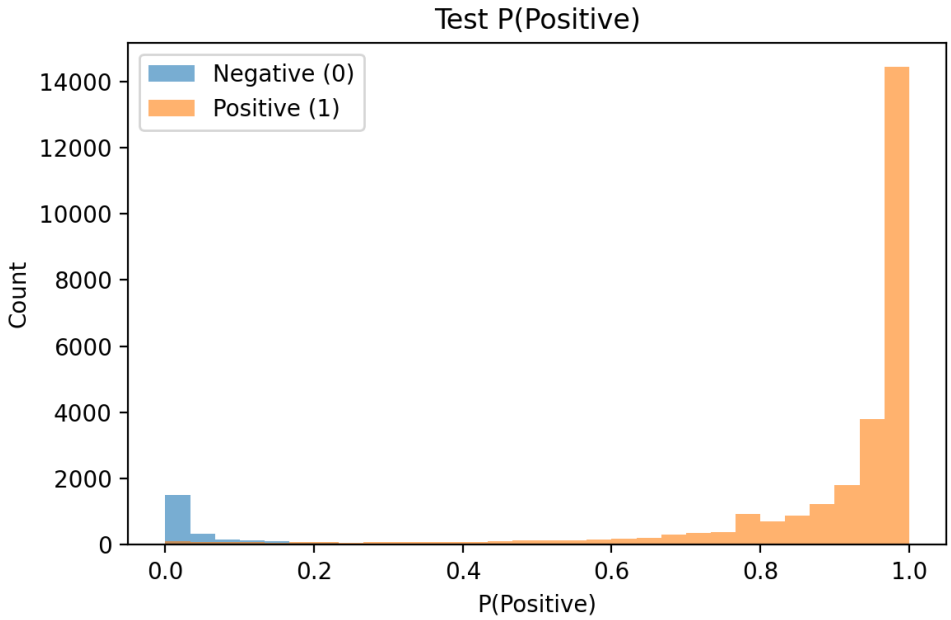

Figure 6: Histogram xác suất trên test strong-label

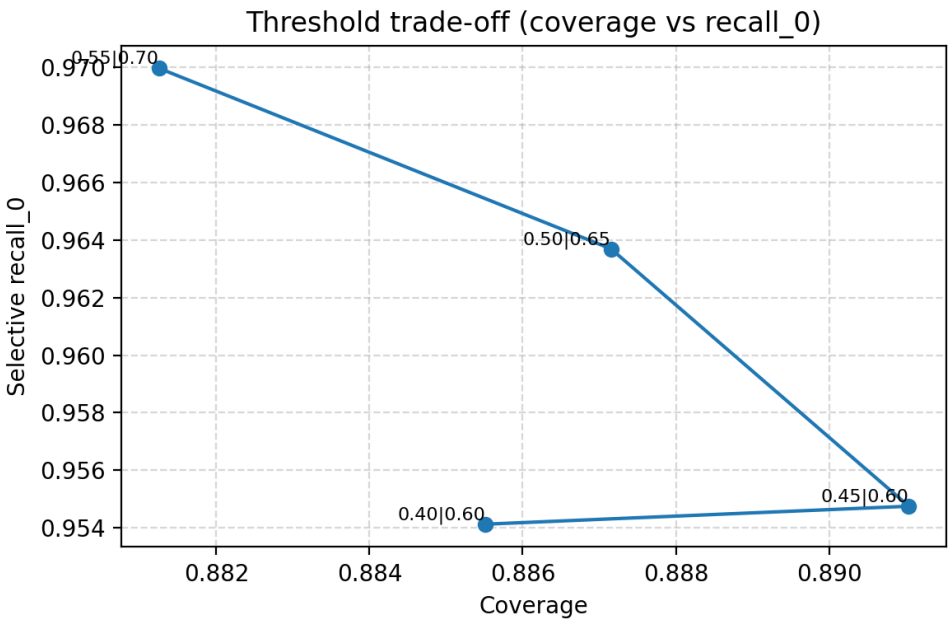

Figure 7: Trade-off ngưỡng của mô hình cổ điển

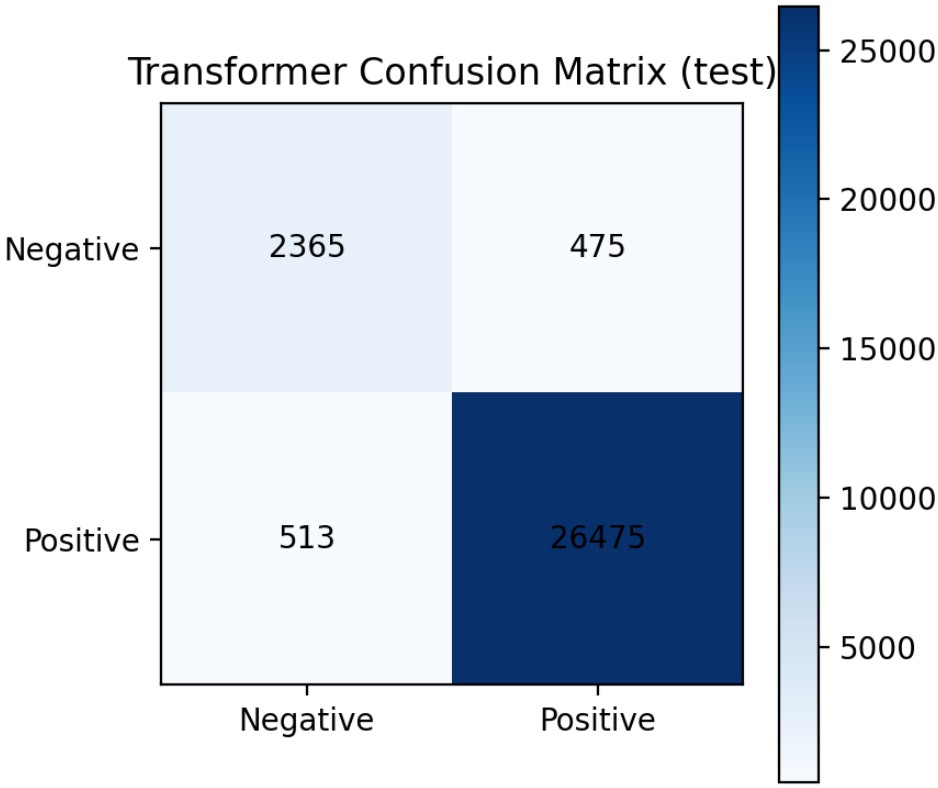

Figure 8: Confusion matrix của transformer sentiment

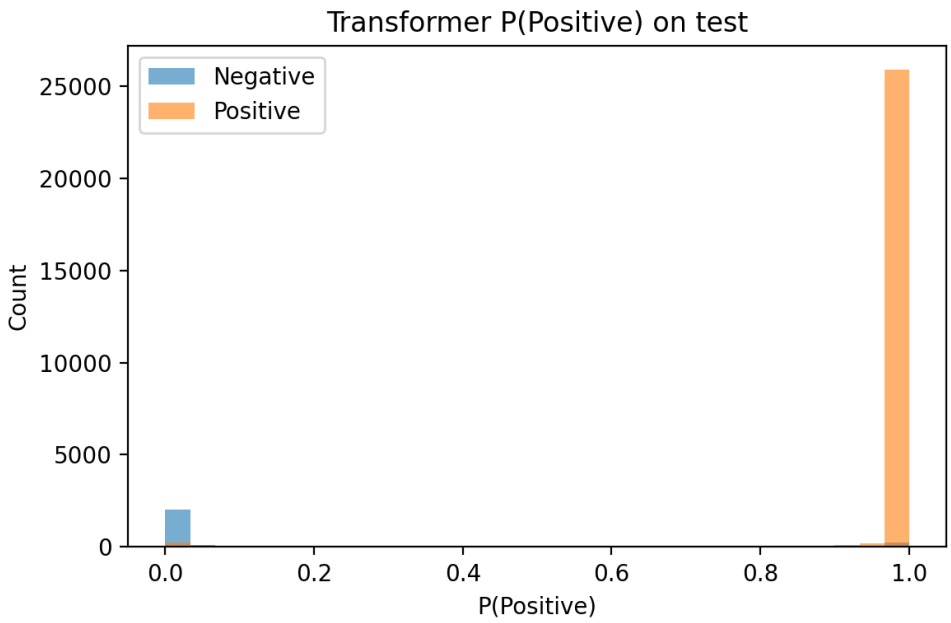

Figure 9: Histogram xác suất của transformer sentiment

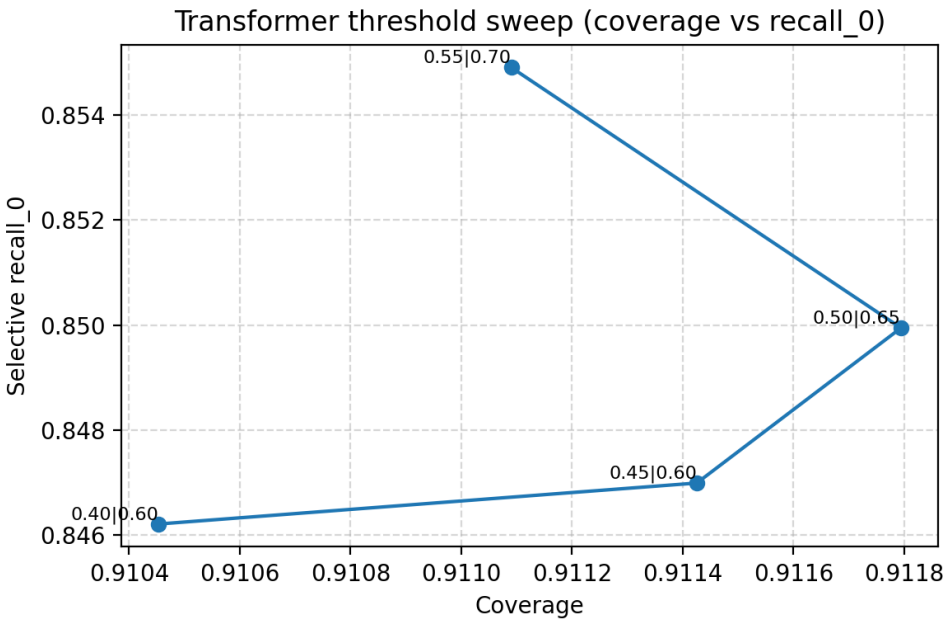

Figure 10: Trade-off ngưỡng của transformer sentiment

Phụ lục B: Hình issue extraction

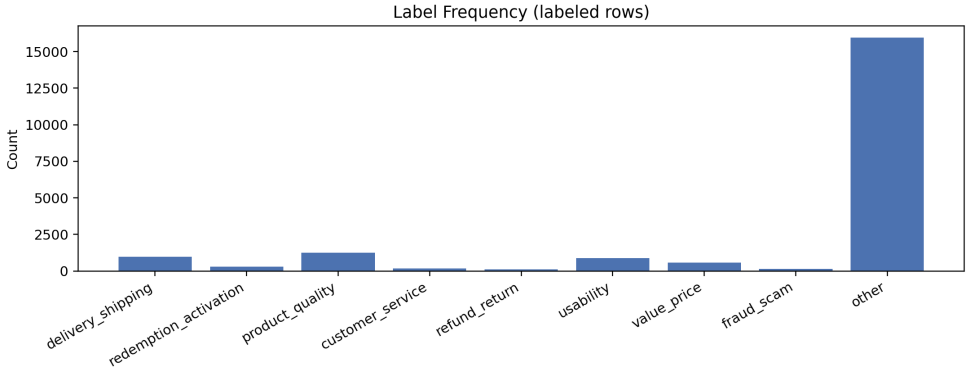

Figure 11: Tần suất nhãn issue

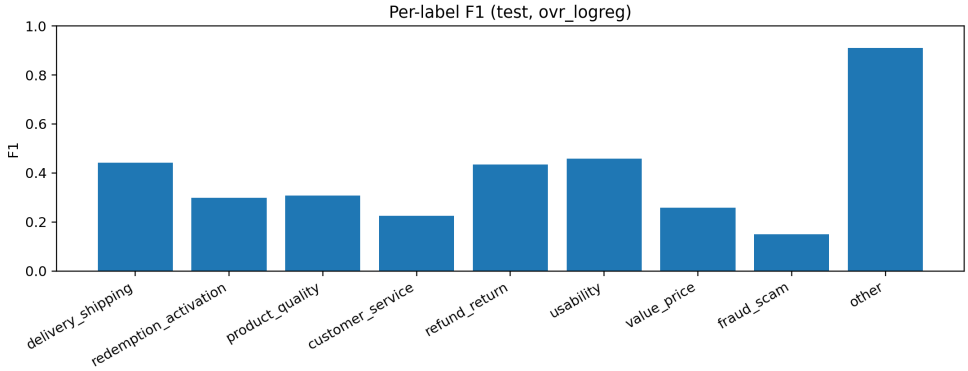

Figure 12: F1 theo nhãn của OVR Logistic

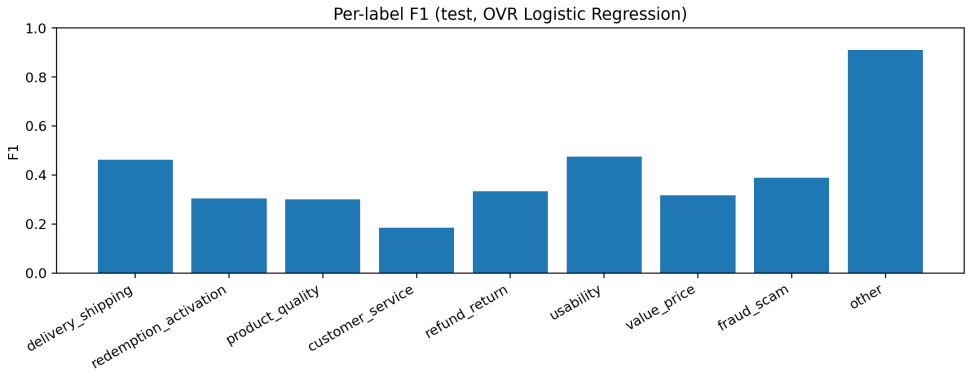

Figure 13: F1 theo nhãn của biến thể word+char

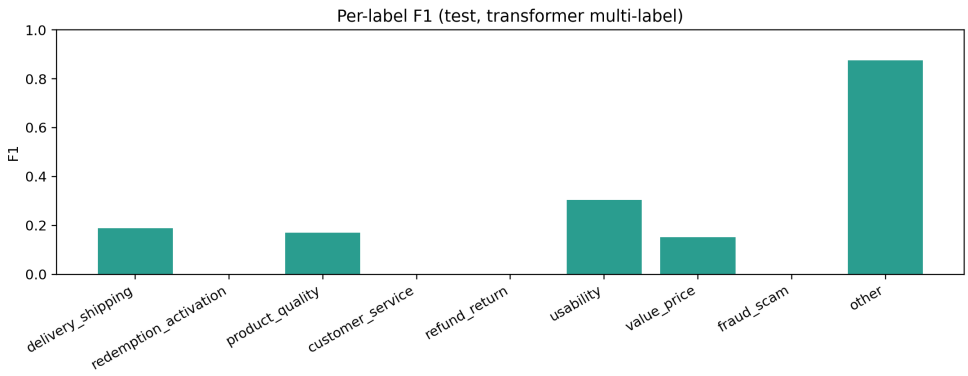

Figure 14: F1 theo nhãn của transformer issue baseline

Phụ lục C: Hình gói nâng cấp giáo trình

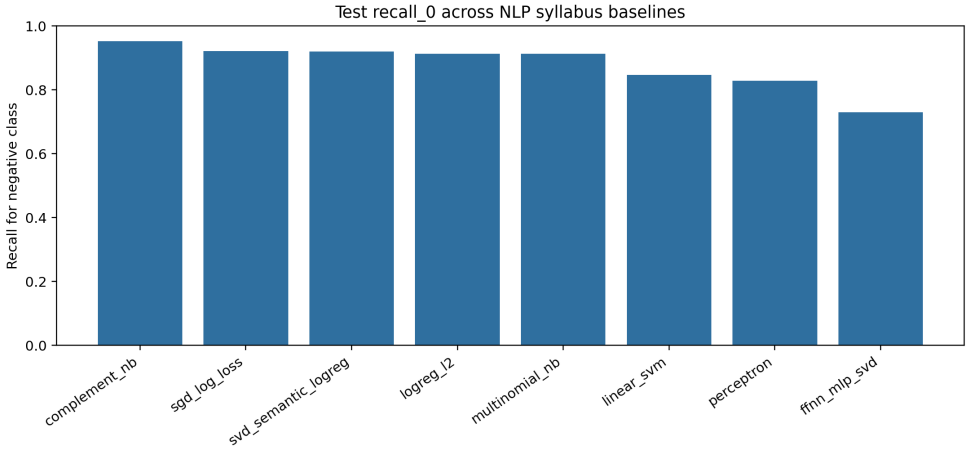

Figure 15: Recall_0 test của các baseline giáo trình

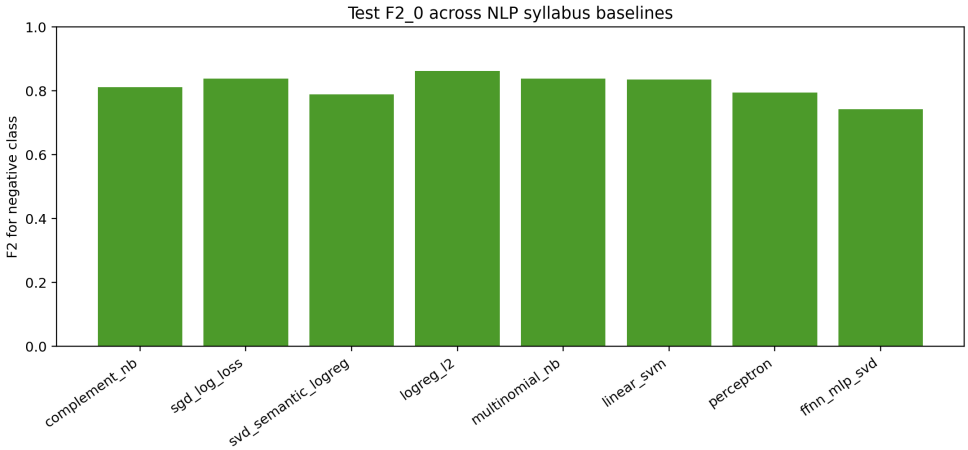

Figure 16: F2_0 test của các baseline giáo trình